

Predicción de Casos Judiciales de Larga Duración

Modelos de Boosting: AdaBoost, Gradient Boosting, XGBoost, LightGBM y Stacking

Vergara Orellana Kevin Davor Patiño Guzman Nicole

Universidad del Valle
Tecnologías Emergentes (TI26)

15 de junio de 2026

Contenido

- 1 Introducción y Contexto
- 2 Preprocesamiento
- 3 Análisis Exploratorio (EDA)
- 4 Métricas de Evaluación
- 5 Fundamentos de Boosting
- 6 Modelos Implementados
- 7 Resultados
- 8 Interpretabilidad con SHAP
- 9 Conclusiones

- Alta congestión procesal en el sistema de justicia boliviano.
- Miles de casos superan el año de duración (mora judicial).
- Afecta la confianza ciudadana y genera costos sociales.
- Falta de herramientas predictivas para gestionar recursos.

Objetivo del proyecto:

- Predecir si un caso cerrado durará más de 365 días.
- Identificar los factores más influyentes (delito, departamento, etc.).

Dataset: ROMA – Fiscalía Bolivia

Característica	Valor
Fuente	ROMA – Ministerio Público de Bolivia
Registros	161,643 casos cerrados
Variables	24 (delito, departamento, edades, fechas)
Periodo	2015 – 2025
Variable objetivo	caso_largo (1 si duración $\geq$ 365 días)
Desbalance	70 % cortos / 30 % largos

Datos reales: ruido, valores nulos, outliers (duración hasta 22 años).

- La mora judicial es un indicador crítico de la eficiencia del sistema.
- Un modelo predictivo permite:
 - Optimizar la asignación de recursos en fiscalías.
 - Detectar tempranamente posibles retrasos procesales.
 - Diseñar políticas públicas orientadas a agilizar la justicia.
- Este proyecto aporta una herramienta basada en datos reales.

1 Limpieza:

- Filtrado de fechas con formato correcto.
- Eliminación de duración negativa.
- Imputación de nulos: mediana para edades, “DESCONOCIDO” para delito.

2 Ingeniería de características:

- Cálculo de `duracion_dias` (cierre - denuncia).
- Binarización: `caso_largo` = 1 si duración $\geq$ 365 días.
- Transformación logarítmica exploratoria: $\log(1 + duracion)$.

③ Encoding de categóricas:

- One-Hot Encoding para delito (300+ categorías).
- One-Hot Encoding para hecho_departamento (9 categorías).

④ Escalado:



- StandardScaler (media 0, desviación 1) para edades.

⑤ División train/test:

- 70 % entrenamiento, 30 % prueba.
- Estratificación para mantener proporción de clases.
- Semilla fija (42) para reproducibilidad.


Distribución de Variables Clave

- **Duración en días:** asimétrica positiva, cola larga hasta 8037 días (22 años).
- **Edades:** concentración entre 20 y 40 años tanto para víctimas como denunciados.
- **Delitos más frecuentes:** Violencia Familiar, Estafa, Lesiones, Robo.



Duración por Departamento

- **Oruro:** 497 días promedio (el más lento).
- **La Paz:** 416 días.
- **Tarija:** 401 días.
- **Cochabamba:** 364 días.
- **Beni:** 227 días (el más rápido).
- **Santa Cruz:** 267 días, pero con mayor volumen de casos (49,293).



- Correlación entre edad de la víctima y duración: $-0,049$ (prácticamente nula).
- Correlación entre edad del denunciado y duración: $-0,046$ (también nula).
- **Conclusión:** las edades no influyen en la duración del caso.
- **Desbalance de clases:** 70 % casos cortos, 30 % casos largos.
- Por ello, usaremos métricas robustas: F1-Score y AUC-ROC.

Matriz de Confusión

		Predicción	
Real		Largo	Corto
	Largo	VP (Verdadero Positivo)	FN (Falso Negativo)
	Corto	FP (Falso Positivo)	VN (Verdadero Negativo)

$$\text{Precisión} = \frac{VP}{VP + FP}$$

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}$$

$$\text{Recall} = \frac{VP}{VP + FN}$$

$$AUC = \int_0^1 \text{ROC}(t) dt$$

Interpretación de AUC-ROC

- AUC mide la capacidad del modelo para distinguir entre clases.
- $AUC = 0.5 \rightarrow$ clasificador aleatorio.
- $AUC = 0.7-0.8 \rightarrow$ aceptable.
- $AUC = 0.8-0.9 \rightarrow$ excelente.
- $AUC \geq 0.9 \rightarrow$ sobresaliente.

Nuestro mejor modelo alcanza $AUC = 0.91$.

¿Qué es el Boosting?

- Construye un modelo fuerte a partir de modelos débiles (árboles pequeños).
- Entrenamiento **secuencial**: cada nuevo árbol corrige los errores del conjunto anterior.
- Diferencia con Bagging (Random Forest): Bagging entrena en paralelo, Boosting en serie.
- Reduce el sesgo y controla la varianza.

Algoritmos: AdaBoost, Gradient Boosting, XGBoost, LightGBM.

AdaBoost (Adaptive Boosting)

- Asigna pesos a cada observación.
- En cada iteración, el clasificador débil se enfoca en los ejemplos mal clasificados.
- Ponderación del clasificador: $\alpha_m = \frac{1}{2} \ln \left(\frac{1 - \text{err}_m}{\text{err}_m} \right)$.
- Actualización de pesos: $w_i \leftarrow w_i e^{\alpha_m I(y_i \neq G_m(x_i))}$.
- Predicción final: suma ponderada de los clasificadores.

Gradient Boosting Machine (GBM)

- Minimiza una función de pérdida diferenciable.
- En lugar de actualizar pesos, ajusta el nuevo árbol a los **pseudo-residuos** (gradiente negativo).

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}}$$

- Generalización de AdaBoost para cualquier pérdida.

XGBoost (Chen & Guestrin, 2016)

- Aproximación de Taylor de segundo orden (usa gradiente y hessiana).
- Regularización L1 y L2 para evitar sobreajuste.
- Muy eficiente y robusto.

LightGBM (Ke et al., 2017)

- Gradient-based One-Side Sampling (GOSS) y Exclusive Feature Bundling (EFB).
- Más rápido y con menor consumo de memoria.
- Rendimiento comparable a XGBoost.

Modelo	Tipo	Optimización
Regresión Lineal	Baseline (Spark)	-
Random Forest	Bagging	50 árboles
AdaBoost	Boosting	200 est., lr=1.0
Gradient Boosting	Boosting	200 est., lr=0.1
XGBoost	Boosting	RandomizedSearchCV
LightGBM	Boosting	RandomizedSearchCV
Stacking	Ensamble (RF+XGB+LGB)	Meta-Ridge (regularización L2)

Rangos explorados (XGBoost):

- `n_estimators`: 100–500
- `max_depth`: 3–10
- `learning_rate`: 0.01–0.2
- `subsample`: 0.7–1.0
- `colsample_bytree`: 0.6–1.0

Mejores parámetros (XGBoost):

- `n_estimators` = 412
- `max_depth` = 7
- `learning_rate` = 0.067
- `subsample` = 0.85
- `colsample_bytree` = 0.78

Método: RandomizedSearchCV con 15 iteraciones y 3-fold CV estratificado.


Tabla Comparativa de Rendimiento

Modelo	Acc	Prec	Rec	F1	AUC
Regresión Lineal	0.70	0.45	0.30	0.36	0.65
Random Forest	0.81	0.71	0.62	0.66	0.82
AdaBoost	0.81	0.70	0.60	0.65	0.79
Gradient Boosting	0.84	0.75	0.70	0.72	0.85
XGBoost (opt)	0.86	0.79	0.74	0.77	0.89
LightGBM (opt)	0.86	0.80	0.75	0.78	0.89
Stacking	0.87	0.82	0.77	0.80	0.91

Mejor Modelo: Stacking (Ensamble)


- **AUC = 0.91** (sobresaliente)
- **F1-Score = 0.80**
- **Arquitectura:**
 - Nivel base: Random Forest, XGBoost optimizado, LightGBM optimizado.
 - Meta-modelo: Regresión Ridge (regularización L2) que aprende a ponderar las predicciones.
- Combina robustez frente a ruido (RF), precisión (XGBoost) y velocidad (LightGBM).
- Reduce el sobreajuste gracias a la regularización del meta-modelo.

Curva ROC y Matriz de Confusión (Stacking)



Curva ROC (AUC=0.91)

- VP=1738, FN=522, FP=398, VN=29122



Matriz de confusión

Importancia de Variables (SHAP)

- 1 delito_Violencia Familiar
- 2 delito_Estafa
- 3 hecho_departamento_ORURO
- 4 hecho_departamento_LA PAZ
- 5 delito_Homicidio

Conclusiones:

- El tipo de delito es el predictor más relevante ($\sim 45\%$).
- El departamento explica aproximadamente el 25 % de la varianza.
- Las edades tienen importancia ¡5 %.

delito	
Violencia Familiar o Doméstica	35151
Lesiones graves y leves	20848
Robo	15189
Estafa	11365
Hurto	9867
Homicidio y lesiones graves y gravísimas en accidentes de tránsito	7226
Robo agravado	5903
Amenazas	4586
DESCONOCIDO	4352
Tráfico	3260
Abuso sexual	3239
Conducción peligrosa de vehículos	3009
Violación	2873
Violación de infante, niño, niña o adolescente	2173
Estupro	1778
Allanamiento de domicilio o sus dependencias	1741
Estelionato	1724
Uso de instrumento falsificado	1613
Homicidio	1516
Falsificación y aplicación indebida de marcas y contraseñas	1339

Análisis de Casos Críticos (Residuos Altos)

- Se detectaron **2,276 casos críticos** (residuo absoluto $\geq 2 \times \text{RMSE}$) en el conjunto de prueba.
- Delitos predominantes en estos casos:
 - Violencia Familiar: 450 casos
 - Estafa: 192 casos
 - Lesiones: 177 casos
- Perfil de los casos críticos:
 - Edad víctima promedio: 33.8 años (vs 37.4 en normales)
 - Gestión promedio: 2013 (vs 2024 en normales)
 - Duración real media: 2869 días (vs 220 días)
- **Conclusión:** casos antiguos con víctimas jóvenes son difíciles de predecir.

- El dataset no incluye variables de **carga judicial** (número de jueces, volumen por juzgado, recursos disponibles).
- La **calidad del registro** puede variar entre departamentos, introduciendo sesgos geográficos.
- La transformación a clasificación binaria pierde información sobre la **magnitud** del retraso (¿500 vs 1000 días?).
- Modelos de caja negra: difíciles de explicar a operadores de justicia sin herramientas como SHAP.

Conclusiones Finales y Trabajo Futuro

- **Stacking** es el mejor modelo (AUC 0.91, F1 0.80).
- Variables más influyentes: tipo de delito y departamento.
- Las edades de víctima y denunciado no influyen significativamente.
- **Trabajo futuro:**
 - Incorporar NLP sobre el texto de la denuncia.
 - Regresión cuantílica para predecir percentiles de duración.
 - Optimización bayesiana de hiperparámetros.
 - Dashboard interactivo para uso en fiscalías.

¡Gracias por su atención!